Clase #02 de 27
Símbolos, Alfabetos y Unicode

Abril 14, Martes

Agenda para esta clase

- Símbolos
- Alfabetos
- Unicode
- Implementación en C

Símbolos ó Caracteres & Alfabetos

[MUCH2012] 1.1.1

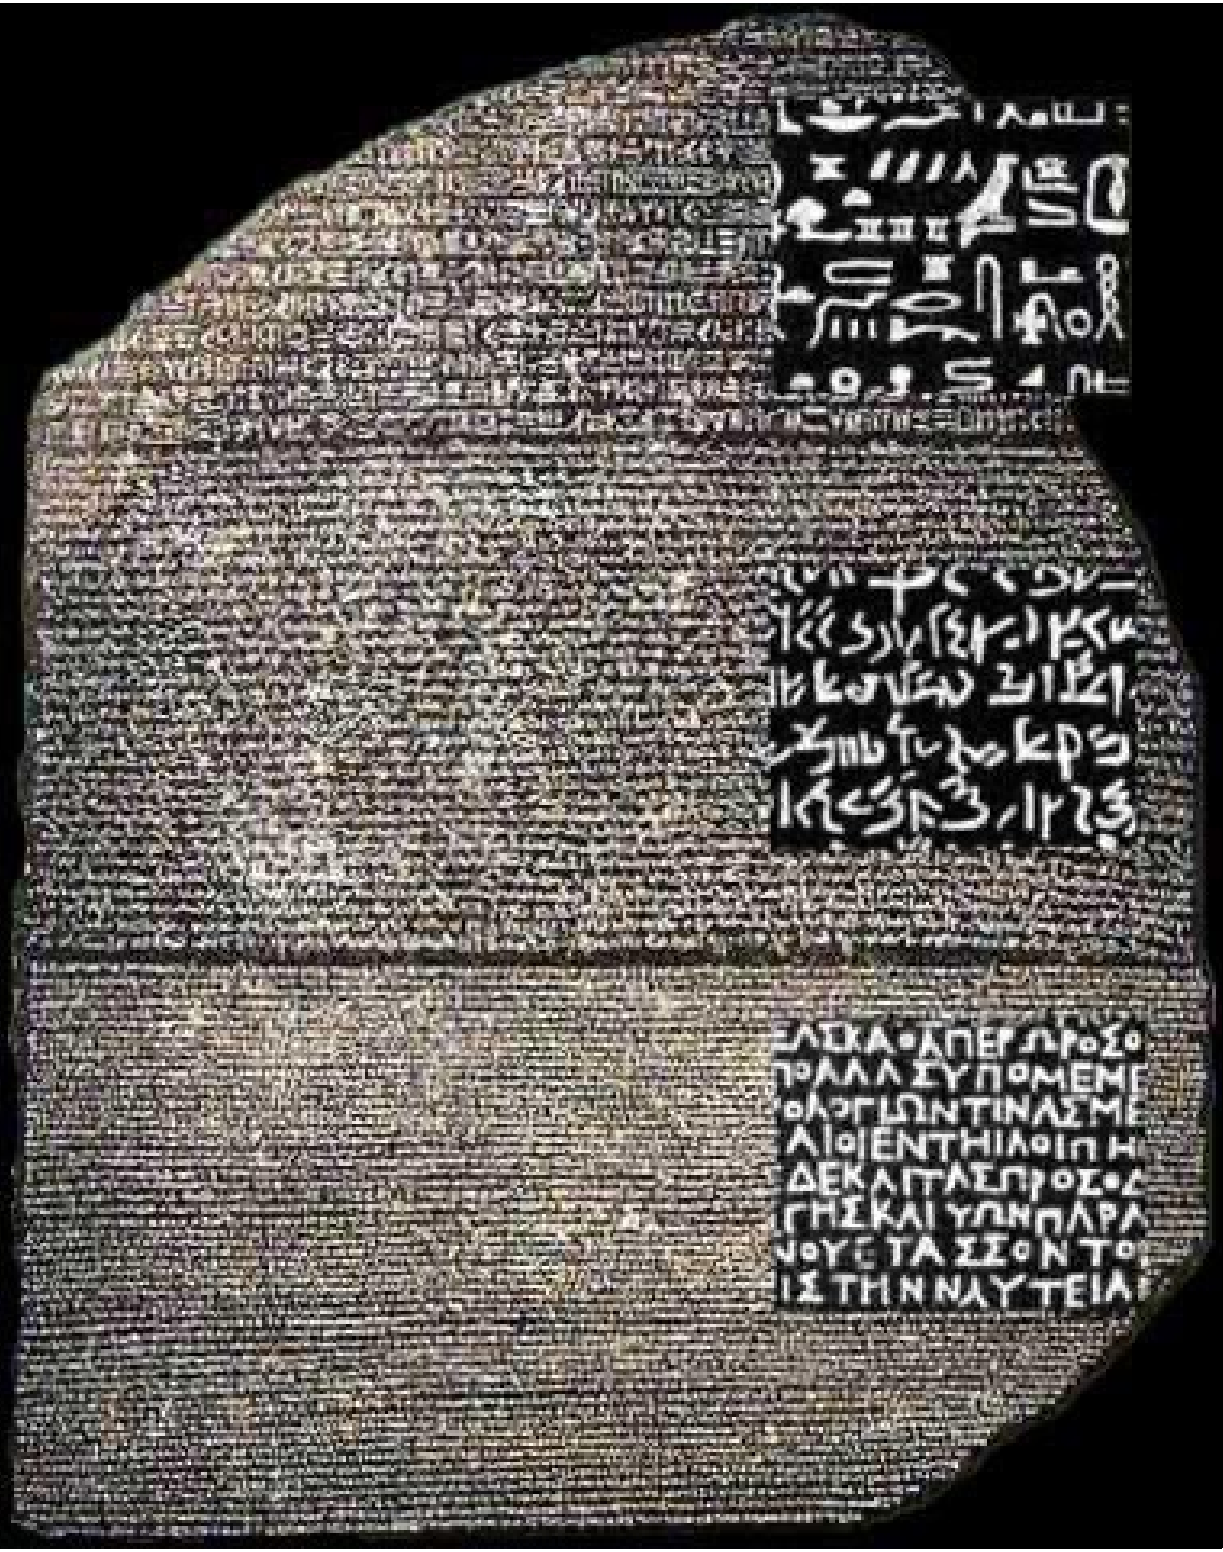

Glifos & Tipografías

Glyphs & Fonts

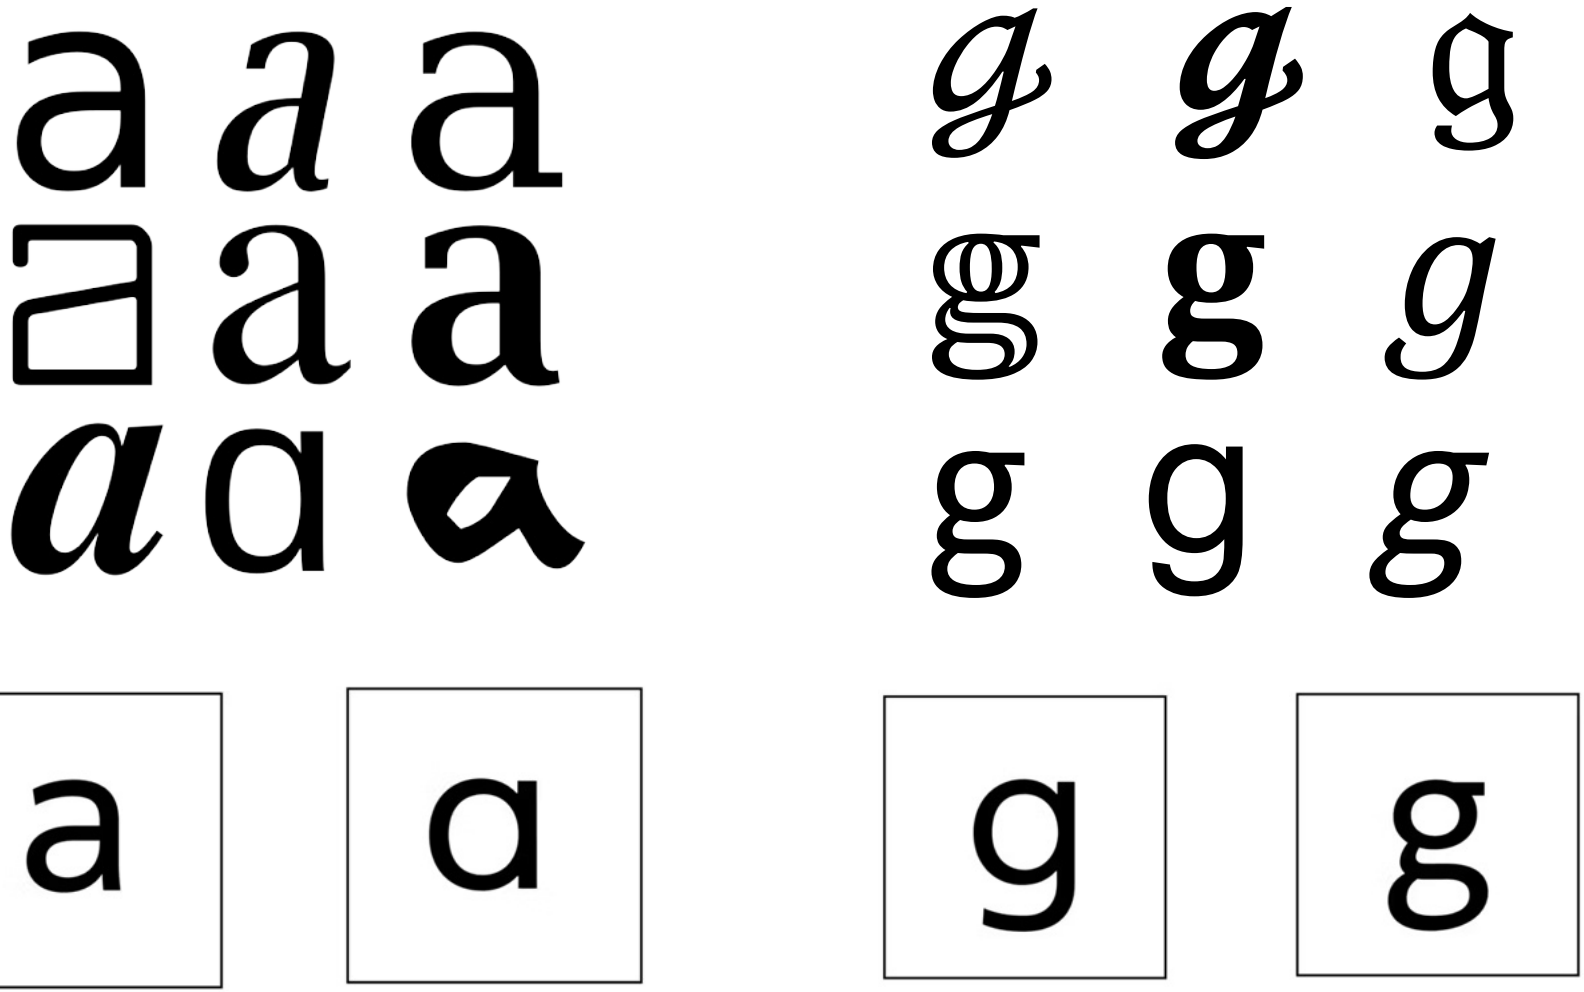

A	ɑ	a	ɑ
U+0041	U+2C6D	U+0061	U+0251

Símbolo o Carácter

- Es Indivisible
- Es *cualquier elemento que se defina como símbolo*
- Pertenece a un Alfabeto (Σ)
- Ejemplo 3 de [MUCH2012] v1c1:
  - El alfabeto Σ = {0, 1} proporciona los caracteres para construir los números binarios
- Ejemplo:
  - El Σ = {if, for} tiene dos caracteres
- Ejercicio 1 de [MUCH2012] v1c1:
  - Escriba el Σ para construir el conjunto de los números enteros con signo en base 10

- Operaciones
  - ***Comparación***
  - ¿Cuál más?
  - ¿Es la ***concatenación*** una operación de símbolos?

Alfabeto Σ (sigma)

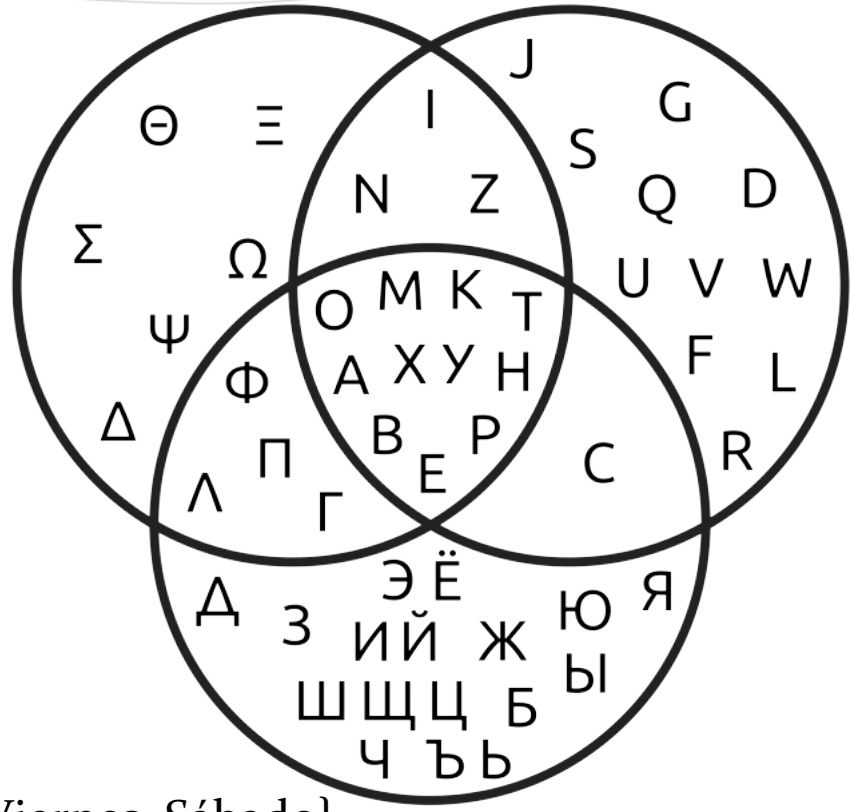

- Es un Conjunto, cuyos elementos son símbolos o caracteres
- Restricciones básicas
  - Finito
  - No vacío
- Ejemplos
  - {} = ∅ ⇒ no es alfabeto, por ser vacío
  - Naturales ⇒ no es alfabeto, por ser infinito
  - ASCII
  - Dígitos = {0, 1, 2, 3, 4, 5, 6, 7, 8, 9}
  - Meses = {Lunes, Martes, Miércoles, Jueves, Viernes, Sábado}
    - No conlleva semántica

- Restricción "avanzada"
  - Sus elementos no pueden formarse por yuxtaposición de otros elementos
- Ejemplos
  - {0,1, 1001}
  - {if, for}
  - {a, b, c, ch, d, e, f, g, h, i, j, k, l, ll, m, n, ñ, o, p, q, r, rr, s, t, u, v, w, x, y, z}.

Alfabeto ASCII & Intro Tipo *char* en C

Alfabeto ASCII

Bits b_4	b_3	b_2	b_1	Column → / Row ↓	0	1	2	3	4	5	6	7
				$b_7 b_6 b_5$	000	001	010	011	100	101	110	111
0	0	0	0	0	NUL	DLE	SP	0	@	P	`	p
0	0	0	1	1	SOH	DC1	!	1	A	Q	a	q
0	0	1	0	2	STX	DC2	"	2	B	R	b	r
0	0	1	1	3	ETX	DC3	#	3	C	S	c	s
0	1	0	0	4	EOT	DC4	$	4	D	T	d	t
0	1	0	1	5	ENQ	NAK	%	5	E	U	e	u
0	1	1	0	6	ACK	SYN	&	6	F	V	f	v
0	1	1	1	7	BEL	ETB	'	7	G	W	g	w
1	0	0	0	8	BS	CAN	(	8	H	X	h	x
1	0	0	1	9	HT	EM	)	9	I	Y	i	y
1	0	1	0	10	LF	SUB	*	:	J	Z	j	z
1	0	1	1	11	VT	ESC	+	;	K	[	k	{
1	1	0	0	12	FF	FS	,	<	L	\	l	|
1	1	0	1	13	CR	GS	—	=	M	]	m	}
1	1	1	0	14	SO	RS	.	>	N	^	n	~
1	1	1	1	15	SI	US	/	?	O	_	o	DEL

https://danq.me/2024/07/21/ascii/

Alfabeto ASCII: Decimales & Sectores

Decimal	Hex	Char	Decimal	Hex	Char	Decimal	Hex	Char	Decimal	Hex	Char
0	00	[NULL]	32	20	[SPACE]	64	40	@	96	60	`
1	01	[START OF HEADING]	33	21	!	65	41	A	97	61	a
2	02	[START OF TEXT]	34	22	"	66	42	B	98	62	b
3	03	[END OF TEXT]	35	23	#	67	43	C	99	63	c
4	04	[END OF TRANSMISSION]	36	24	$	68	44	D	100	64	d
5	05	[ENQUIRY]	37	25	%	69	45	E	101	65	e
6	06	[ACKNOWLEDGE]	38	26	&	70	46	F	102	66	f
7	07	[BELL]	39	27	'	71	47	G	103	67	g
8	08	[BACKSPACE]	40	28	(	72	48	H	104	68	h
9	09	[HORIZONTAL TAB]	41	29	)	73	49	I	105	69	i
10	0A	[LINE FEED]	42	2A	*	74	4A	J	106	6A	j
11	0B	[VERTICAL TAB]	43	2B	+	75	4B	K	107	6B	k
12	0C	[FORM FEED]	44	2C	,	76	4C	L	108	6C	l
13	0D	[CARRIAGE RETURN]	45	2D	-	77	4D	M	109	6D	m
14	0E	[SHIFT OUT]	46	2E	.	78	4E	N	110	6E	n
15	0F	[SHIFT IN]	47	2F	/	79	4F	O	111	6F	o
16	10	[DATA LINK ESCAPE]	48	30	0	80	50	P	112	70	p
17	11	[DEVICE CONTROL 1]	49	31	1	81	51	Q	113	71	q
18	12	[DEVICE CONTROL 2]	50	32	2	82	52	R	114	72	r
19	13	[DEVICE CONTROL 3]	51	33	3	83	53	S	115	73	s
20	14	[DEVICE CONTROL 4]	52	34	4	84	54	T	116	74	t
21	15	[NEGATIVE ACKNOWLEDGE]	53	35	5	85	55	U	117	75	u
22	16	[SYNCHRONOUS IDLE]	54	36	6	86	56	V	118	76	v
23	17	[END OF TRANS. BLOCK]	55	37	7	87	57	W	119	77	w
24	18	[CANCEL]	56	38	8	88	58	X	120	78	x
25	19	[END OF MEDIUM]	57	39	9	89	59	Y	121	79	y
26	1A	[SUBSTITUTE]	58	3A	:	90	5A	Z	122	7A	z
27	1B	[ESCAPE]	59	3B	;	91	5B	[	123	7B	{
28	1C	[FILE SEPARATOR]	60	3C	<	92	5C	\	124	7C	|
29	1D	[GROUP SEPARATOR]	61	3D	=	93	5D	]	125	7D	}
30	1E	[RECORD SEPARATOR]	62	3E	>	94	5E	^	126	7E	~
31	1F	[UNIT SEPARATOR]	63	3F	?	95	5F	_	127	7F	[DEL]

https://danq.me/2024/07/21/ascii/

Lógica atrás del orden de ASCII

Bits b_4	b_3	b_2	b_1	Row \ Column	0 (000)	1 (001)	2 (010)	3 (011)	4 (100)	5 (101)	6 (110)	7 (111)
0	0	0	0	0	NUL	DLE	SP	0	@	P	`	p
0	0	0	1	1	SOH	DC1	!	1	A	Q	a	q
0	0	1	0	2	STX	DC2	"	2	B	R	b	r
0	0	1	1	3	ETX	DC3	#	3	C	S	c	s
0	1	0	0	4	EOT	DC4	$	4	D	T	d	t
0	1	0	1	5	ENQ	NAK	%	5	E	U	e	u
0	1	1	0	6	ACK	SYN	&	6	F	V	f	v
0	1	1	1	7	BEL	ETB	'	7	G	W	g	w
1	0	0	0	8	BS	CAN	(	8	H	X	h	x
1	0	0	1	9	HT	EM	)	9	I	Y	i	y
1	0	1	0	10	LF	SUB	*	:	J	Z	j	z
1	0	1	1	11	VT	ESC	+	;	K	[	k	{
1	1	0	0	12	FF	FS	,	<	L	\	l	|
1	1	0	1	13	CR	GS	—	=	M	]	m	}
1	1	1	0	14	SO	RS	.	>	N	^	n	~
1	1	1	1	15	SI	US	/	?	O	_	o	DEL

011 _ _ _ _

48	30	0
49	31	1
50	32	2
51	33	3
52	34	4
53	35	5
54	36	6
55	37	7
56	38	8
57	39	9

100 _ _ _ _

65	41	A
66	42	B
67	43	C
68	44	D
69	45	E
70	46	F

110 _ _ _ _

97	61	a
98	62	b
99	63	c
100	64	d
101	65	e
102	66	f

000 0000	NUL	010 0000		100 0000	@	110 0000	`
000 0001	SOH	010 0001	!	100 0001	A	110 0001	a
000 0010	STX	010 0010	"	100 0010	B	110 0010	b
000 0011	ETX	010 0011	#	100 0011	C	110 0011	c
000 0100	EOT	010 0100	$	100 0100	D	110 0100	d
000 0101	ENQ	010 0101	%	100 0101	E	110 0101	e
000 0110	ACK	010 0110	&	100 0110	F	110 0110	f
000 0111	BEL	010 0111	'	100 0111	G	110 0111	g
000 1000	BS	010 1000	(	100 1000	H	110 1000	h
000 1001	HT	010 1001	)	100 1001	I	110 1001	i
000 1010	LF	010 1010	*	100 1010	J	110 1010	j
000 1011	VT	010 1011	+	100 1011	K	110 1011	k
000 1100	FF	010 1100	,	100 1100	L	110 1100	l
000 1101	CR	010 1101	-	100 1101	M	110 1101	m
000 1110	SO	010 1110	.	100 1110	N	110 1110	n
000 1111	SI	010 1111	/	100 1111	O	110 1111	o
001 0000	DLE	011 0000	0	101 0000	P	111 0000	p
001 0001	DC1	011 0001	1	101 0001	Q	111 0001	q
001 0010	DC2	011 0010	2	101 0010	R	111 0010	r
001 0011	DC3	011 0011	3	101 0011	S	111 0011	s
001 0100	DC4	011 0100	4	101 0100	T	111 0100	t
001 0101	NAK	011 0101	5	101 0101	U	111 0101	u
001 0110	SYN	011 0110	6	101 0110	V	111 0110	v
001 0111	ETB	011 0111	7	101 0111	W	111 0111	w
001 1000	CAN	011 1000	8	101 1000	X	111 1000	x
001 1001	EM	011 1001	9	101 1001	Y	111 1001	y
001 1010	SUB	011 1010	:	101 1010	Z	111 1010	z
001 1011	ESC	011 1011	;	101 1011	[	111 1011	{
001 1100	FS	011 1100	<	101 1100	\	111 1100	|
001 1101	GS	011 1101	=	101 1101	]	111 1101	}
001 1110	RS	011 1110	>	101 1110	^	111 1110	~
001 1111	US	011 1111	?	101 1111	_	111 1111	DEL

Caracteres y Alfabetos – Su Implementación en C

- Alfabeto: Tipo de dato char
- Carácter: Valor y variable
- Valor:

  A

  - Literal 'A'
  - Literal 65
- Variable
  - $c \in \Sigma$
    - char c;

Unicode

Universal Coded Character Set

Los Límites de ASCII: Ñ 平和

- **i18n**
  - **I***nternationalizatio***n**
  - Internalización

- Unicode (ISO/IEC 10646 series)
  - ¿Cuántos caracteres posibles? 1.111.998
  - La versión más reciente mapea 159.801 caracteres
  - 2^{21} es *suficiente*, 2^{24} para redondear a múltiplos de 8
  - Pero 2^{32} es más *eficiente* para arquitecturas de 32 o 64 bits.

Puntos de Código & Grafemas

U+0041 = A

n + ◌̃ = ñ
U+006E + U+0303 ≃ U+00F1

N + ◌̃ = Ñ
U+004E + U+0303 ≃ U+00D1

👍
U+1F44D

👍🏽
U+1F44D + U+1F3FD

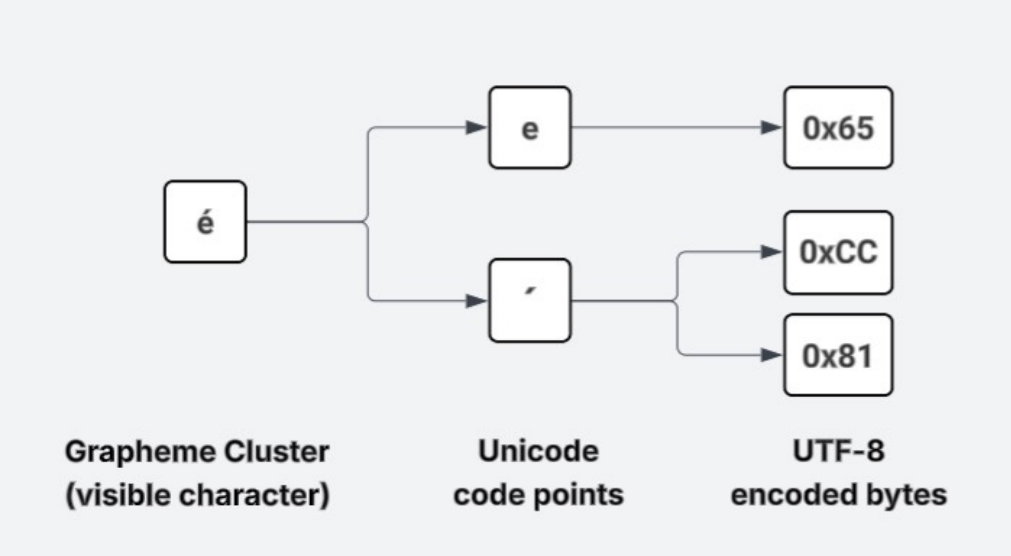

Preguntas de Repaso

1. ¿Qué es un símbolo?
2. ¿Qué es un alfabeto?
3. ¿Qué es ASCII?
4. ¿Para qué se creó Unicode?
5. ¿Qué es char?

Términos de la clase

Definir cada término con la bibliografía

- Glifo
- Símbolo o carácter en LF
- Operaciones sobre caracteres
- Alfabeto Σ en LF
- Símbolo o carácter en C
- ASCII
- Carácter de control
- Alfabeto en C
- Unicode
- Puntos de Código
- Grafemas

Referencias Bibliográficas

- Unicode: ISO/IEC 10646
- ASCII: ISO646-US
- K&R: 1.5 Character Input and Output
- MUCH: 1.1 CARACTERES y ALFABETOS

Tareas para la próxima clase

1. Leer sobre UTF-8
2. Leer sobre Cadenas

¿Consultas?

Fin de la clase